

Selección de Comportamientos básicos de Conducción usando MDP-ProbLog y Webots¹

Motivación

Héctor Avilés, Karina Arévalo

havilesa@upv.edu.mx

Universidad Politécnica de Victoria

Escuela de Invierno de Robótica 2022-2023

11-12 de enero del 2023

¹En trabajo conjunto con Marco Negrete (FI-UNAM), Rubén Machucho (UPV), Alberto Reyes (IEE)

Contenido

- Día 1:
 - Introducción (20 min)
 - Prolog y ProbLog (30 min)
 - MDP-ProbLog/Webots (70 min)
- Día 2:
 - Programación en MDP-ProbLog/Obtención de una política/integración en Webots (100 min)
 - Presentación de proyectos (15 min)
 - Resumen (5 min)

Objetivo

- ¿Qué buscamos en esta plática?:
 - Desarrollar una política de acción útil para la selección de comportamientos básicos de conducción para coche autónomo simulado usando **MDP-ProbLog**, herramienta para modelar la toma de decisiones con lógica probabilística
 - Prerequisitos: Conocimientos básicos de lógica de predicados, Prolog, y teoría de probabilidad son deseables

- La plática se desarrollará de la siguiente manera:
 - Presentación de las ideas generales
 - Descripción de códigos ejemplo (Prolog, Problog y MDP-ProbLog)
 - Codificación y presentación de ejercicios por parte del alumno

Introducción

- La **inteligencia artificial** (IA) y (parte de) la **robótica** buscan la construcción de máquinas que *emulen*² procesos perceptuales, cognitivos, de comunicación o de acción considerados “inteligentes”^{3,4} que sean útiles para los seres humanos

²Copiar, imitar, reproducir o simular funcionalidades (posiblemente ejecutando de manera distinta al original)

³De acuerdo a las acepciones de la *RAE*: Capacidad de entender, comprender, resolver problemas, desplegar habilidad, destreza o experiencia

⁴Otra vision considera a la IA útil para entender a la **inteligencia humana** ▶

Introducción

- Existen dos grandes visiones en la IA:
 - La **IA simbólica**⁵ (eg, sistemas expertos, planeadores, procesamiento de lenguaje natural)
 - La **IA sub-simbólica**⁶ (eg, inferencia Bayesiana, redes neuronales, algoritmos genéticos, aprendizaje profundo)

⁵Conocida igualmente como *IA clásica*, *IA basada en reglas*, *IA de la vieja escuela*, ó *sistemas basados en conocimiento*

⁶También llamada *IA estadística*, *conexionista*, ó *inteligencia computacional* no serán consideradas en esta plática

Introducción

- En IA simbólica, la **representación del conocimiento** (usualmente proposiciones⁷) se basa en símbolos que se manipulan para derivar nuevo conocimiento^{8,9}

⁷Objetos y sus propiedades y relaciones

⁸Ya que en general no es posible registrar con antelación todo el conocimiento

⁹En el contexto de algún *sistema formal* (eg, *frames*, ontologías, **programación lógica**, etc.) que está compuesto por primitivas, reglas sintácticas para expresiones válidas, expresiones válidas que se suponen verdaderas y reglas para derivar nuevas expresiones

Introducción

- Las representaciones simbólicas tienen diversas ventajas:
 - Utilizan una representación del conocimiento “entendible” para el ser humano y sus formalismos pueden ser inspeccionados fácilmente
 - Son apropiadas para dominios bien delimitados y adaptables manualmente a otros dominios (suficientemente) cercanos
 - Describen conocimiento obtenido de expertos
 - Permiten una organización jerárquica de los componentes de los mismos¹⁰
 - Pueden incluirse mecanismos para explicar sus conclusiones y verificar sus razonamientos paso a paso

¹⁰eg, la familia Pérez la forman Juan y María que son esposos y Pedro que es su hijo

Introducción

- Sin embargo, los sistemas simbólicos tradicionales presentan algunas desventajas:
 - Difícil escalarlos a instancias más complejas de un mismo problema o extenderlos a otros ámbitos
 - Son contruidos manualmente y aunque hay avances, no es fácil el aprendizaje estructural ni hacer que aprendan por si mismos
 - Se requiere de expertos y de su capacidad (o disposición) para compartir su conocimiento
 - No son prácticos para analizar datos masivos o “desordenados”¹¹
 - Siguen un procesamiento secuencial (no hay paralelismo)
 - Requieren adecuaciones para manejar **incertidumbre**
 - Siguen la *suposicion de mundo cerrado*¹²

¹¹eg, el reconocimiento de objetos en imágenes arbitrarias requeriría de un número grande de reglas

¹²Lo que es verdad del mundo está en el conocimiento del sistema o es derivable de ese conocimiento y lo demás es falso

Introducción

- Recientemente ha crecido el interés de combinar las capacidades de los sistemas sub-simbólicos¹³ con la posibilidad de explicación y verificación de las técnicas simbólicas, indispensables en áreas críticas actuales¹⁴:
 - Un paso en ese sentido es la **lógica probabilística**¹⁵

¹³ Algunas de las debilidades del enfoque simbólico son mejor abordadas por los sistemas sub-simbólicos (eg, aprendizaje de la experiencia a partir de datos estadísticos y recompensas), manejo de incertidumbre, grandes volúmenes de datos, datos poco estructurados, procesamiento paralelo, extracción de atributos, representación numérica)

¹⁴ eg, actuación ética, protección de datos personales o responsabilidad legal de los sistemas inteligentes

¹⁵ La combinación de la lógica y la teoría de probabilidad

- Existen 3 vertientes principales en la lógica probabilística:
 - Combinación de la lógica y la teoría de probabilidad en nuevas teorías con características de ambos
 - Incorporación de nociones de razonamiento lógico a modelos probabilistas
 - Integración de probabilidades a esquemas de razonamiento lógico

Introducción

- La adición de probabilidades a **programas lógicos**¹⁶ flexibiliza los valores de verdad binarios ($\{V, F\}$) a valores en el intervalo $[0, 1]$, lo cual permite:
 - Extender el razonamiento deductivo con inferencias probabilistas¹⁷
 - Obtener descripciones basadas en reglas (¿más claras y transparentes?) de modelos de probabilidad
 - Considerar técnicas de aprendizaje estadístico en los programas lógicos (*no cubiertas en esta plática*)

¹⁶eg, en Prolog

¹⁷eg, obtener la explicación más probable dada una evidencia

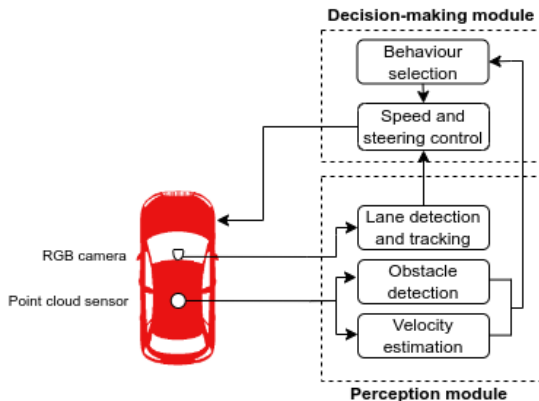
Introducción

- Los coches autónomos proponen beneficios potenciales en seguridad y salud de los pasajeros, de la economía y medio ambiente
- Los módulos que componen la arquitectura de estos vehículo pueden clasificarse en dos grandes bloques:
 - **Percepción:** Uso de sensores para identificar la “situación” actual del coche autónomo y el ambiente
 - **Toma de decisiones:** Estructuración de información disponible y de acciones para alcanzar un objetivo (eg., moverse, evadir obstáculos, respetar reglas de conducción, etc.)

Introducción

- Este taller se enfoca en la selección de comportamientos, el análisis visual de la escena y el controlador del coche:
 - La percepción involucra análisis visual en imágenes RGB y nube de puntos para detectar coches alrededor del vehículo autónomo y el carril derecho de la carretera
 - La selección de comportamientos consiste en la elección de una acción asociada usando MDP-ProbLog
 - El controlador determina la velocidad y giro del coche de acuerdo a las entradas del análisis visual y del comportamiento seleccionado

Introducción




"Avilés, H., Negrete, M., Machucho, R., Rivera, K., Trejo, D., Vargas, H. (2022). Probabilistic Logic Markov Decision Processes for Modeling Driving Behaviors in Self-driving Cars. In: Bicharra Garcia, A.C., Ferro, M., Rodríguez Ribón, J.C. (eds) Advances in Artificial Intelligence – IBERAMIA 2022. IBERAMIA 2022. Lecture Notes in Computer Science(), vol 13788. Springer, Cham.

Introducción



a)



b)

Robots utilizados: a) Robot simulado (Webots) y b) robot AutoMiny V.4 de la Universidad Libre de Berlín (CIMAT-Consorcio IA)

Introducción

Video(s)

“navigation_static_obstacles_rear.mp4” ,
“navigation_dynamic_obstacles_rear.mp4” y
“navigation_keep_distance_front.mp4”

Introducción

¿Preguntas?

Bibliografía

- Michael Negnevitsky. Artificial Intelligence: A Guide to Intelligent Systems. Addison-Wesley Longman Publishing Co., Inc. 2001.
- Nils J. Nilsson. Artificial Intelligence: A New Synthesis. Morgan Kaufmann. 1998.
- Stuart Russell, Peter Norvig. Artificial Intelligence: A Modern Approach, 3rd Ed. Prentice Hall. 2010.
- Ronald Brachman, Hector Levesque. Knowledge representation and reasoning. Morgan Kaufmann Publishers Inc. 2004.
- Eleni Ilkou, Maria Koutraki. Symbolic Vs Sub-symbolic AI Methods: Friends or Enemies? Proceedings of the CIKM 2020 Workshops. 2020.
- Fabrizio Riguzzi, Theresa Swift. A Survey of Probabilistic Logic Programming. Declarative Logic Programming. 2018
- David S. Warren. Programming in Tabled Prolog (very) DRAFT. 2020. Disponible en: <https://www3.cs.stonybrook.edu/~warren/xsbbook/book.html>. Última visita: 9 de enero del 2022.

Bibliografía

- Taisuke Sato. A Statistical Learning Method for Logic Programs with Distribution Semantics. Logic Programming: The 12th Conference, págs. 715-729. 1995.
- Taisuke Sato, Yoshitaka Kameya. PRISM: A Language for Symbolic-Statistical Modeling. Proceedings of the Fifteenth International Joint Conference on Artificial Intelligence, volumen 2, págs 1330-1335. 1997.
- Nils J. Nilsson. Shakey the robot. Artificial Intelligence Center. Computer Science and Technology Division Technical Note 323. SRI International. 1984.
- James M. Henle, Jay L. Garfield, Thomas Tymoczko. Sweet Reason: A Field Guide to Modern Logic. 2nd. Ed. Wiley-Blackwell. 2012.
- J. W. Lloyd. Foundations of Logic Programming. 2nd. Ed. Springer-Verlag. 1993.
- Ben Copping. Artificial Intelligence Illuminated. Jones & Bartlett Publishing. 2004.
- Derek Goldrei. Propositional and Predicate Calculus: A Model of Argument. Springer. 2005.

Bibliografía

- Hodges, Wilfrid, "Model Theory". The Stanford Encyclopedia of Philosophy (Winter 2020 Edition), Edward N. Zalta (ed.), Disponible en: <https://plato.stanford.edu/archives/win2020/entries/model-theory>.
- Ulf Nilsson and Jan Maluszynski, Logic, Programming and Prolog, 2nd Ed. 2000.
- Chin-Liang Chang, Richard Char-Tung Lee. Symbolic Logic and Mechanical Theorem Proving. Academic Press. 1973.
- Michael Genesereth, Eric Kao. Herbrand Semantics. Disponible en: <http://logic.stanford.edu/herbrand/herbrand.html>. Última visita: 15 de diciembre del 2021.
- Michael Genesereth, Eric Kao. The Herbrand Manifesto: Thinking Inside the Box. Disponible en: <http://intrologic.stanford.edu/extras/manifesto.html>. Última visita: 15 de diciembre del 2021.
- Johan Bos. Drawing Prolog Search Trees: A Manual for Teachers and Students of Logic Programming. Licencia CC BY 4.0. Computing Research Repository (CoRR). Disponible en: https://www.researchgate.net/publication/338762840_Drawing_Prolog_Search_Trees_A_Manual_for_Teachers_and_Students_of_Logic_Programming. Última visita: 15 de diciembre del 2021.

Bibliografía

- Luc De Raedt, Angelika Kimmig. Probabilistic (logic) programming concepts. Machine Learning volume 100, págs. 5-47. 2015.
- Ulle Endriss. Lecture Notes: An Introduction to Prolog Programming. Institute for Logic, Language and Computation. University of Amsterdam. 2014. Disponible en: <https://staff.fnwi.uva.nl/u.endriss/teaching/prolog/prolog.pdf>. Última visita: 15 de diciembre del 2021.
- Patrick Blackburn, Johan Bos, and Kristina Striegnitz. Learn Prolog Now! Disponible en: <http://www.let.rug.nl/bos/lpn//lpnpag.php?pageid=top>. Última visita: 15 de diciembre del 2021.
- Judea Pearl. Probabilistic reasoning in intelligent systems: networks of plausible inference. 2nd Ed. Morgan Kaufmann. 2014.
- Luis Enrique Sucar. Probabilistic Graphical Models: Principles and Applications, 2nd ed. Springer International Publishing. 2021.

Bibliografía

- Marek Sergot. 491 Knowledge Representation: Minimal models and fixpoint semantics for definite logic programs. Disponible en: https://www.doc.ic.ac.uk/~mjs/teaching/KnowledgeRep491/Fixpoint_Definite_491-2x1.pdf. Última visita: 15 de diciembre del 2021.
- Lawrence R. Rabiner, Readings in Speech Recognition, chapter: A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition. Morgan Kaufmann Publishers. 1990.
- Pat Langley, Wayne Iba, Kevin Thompson. An analysis of Bayesian classifiers. In National Conference on Artificial Intelligence, pages 223–228. 1992.
- Daan Fierens, Guy Van den Broeck, Joris Renkens, Dimitar Sht. Shterionov, Bernd Gutmann, Ingo Thon, Gerda Janssens, Luc De Raedt. Inference and learning in probabilistic logic programs using weighted Boolean formulas. Theory and Practice of Logic Programming 15(03). 2013.
- Jesse Hoey, Robert St-Aubin, Alan J Hu, Craig Boutilier, SPUDD: Stochastic Planning Using Decision Diagrams, Proceedings of Uncertainty in Artificial Intelligence. 1999.

Bibliografía

- Thiago P. Bueno, Denis D. Mauá, Leliane N. de Barros Fabio G. Cozman. Markov Decision Processes Specified by Probabilistic Logic Programming: Representation and Solution. 5th Brazilian Conference on Intelligent Systems. Págs. 337-342. 2016
- Richard S. Sutton and Andrew G. Barto. Reinforcement Learning: An Introduction 2nd Ed. (in progress). The MIT Press. Disponible en: <https://web.stanford.edu/class/psych209/Readings/SuttonBartoIPRLBook2ndEd.pdf>. Última visita: 28 de diciembre del 2021.
- Maya R. Gupta. A Measure Theory Tutorial (Measure Theory for Dummies). UWEE Technical Report Number UWEETR-2006-0008. Department of Electrical Engineering. University of Washington. 2006. Disponible en: <https://vannevar.ece.uw.edu/techsite/papers/documents/UWEETR-2006-0008.pdf>. Última visita: 30 de diciembre del 2021.
- Athanasios Papoulis. Probability & Statistics. Prentice Hall. 1990.

Bibliografía

- Ralitsa Dardjonova. Resolution in FOL. 2020. Disponible en: <https://www21.in.tum.de/teaching/sar/SS20/3.pdf>. Última visita: 2 de enero del 2022.
- William W. Hines, Douglas C. Montgomery. Probabilidad y Estadística para Ingeniería y Administración. 3ra. edición en inglés, 2da. en español. Compañía Editorial Continental. 1996.
- Jay L. DeVore. Probabilidad y Estadística para Ingeniería y Ciencias. Sexta Ed. Thomson. 2005.
- Robert Kowalski. Logic Programming. Handbook of the History of Logic. Elsevier. Volume 9. Págs. 523-569. 2014.
- Uwe Schöning. Logic for Computer Scientists. Birkhäuser. 2008.
- Neil Immerman. Converting FO Formula to Equivalent Formula in Rectified Prenex Normal (RPF) Form. Curso CMPSCI 513 Logic in Computer Science. Disponible: <https://people.cs.umass.edu/~immerman/cs513/prenexAlgorithm.pdf>. Última visita: 6 de enero del 2022.